

# アダプタマージによるスケーラブルなドメイン増分学習

三原 大和<sup>†</sup>      福田 拓真<sup>‡</sup>      川本 一彦<sup>§</sup>  
千葉大学<sup>†</sup>      千葉大学<sup>‡</sup>      千葉大学<sup>§</sup>

## 1 はじめに

ドメイン増分学習では、段階的に変化するドメイン（データ分布）に適応しつつ、過去のドメインデータにアクセスできない制約のもとで、過去の知識を失わずに継続学習する必要がある [1]。この制約のために、破滅的忘却 [2] が主な課題となる。さらに、ドメインの増加に伴い推論時間が増加せず、スケーラブルな推論が可能であることが実応用の観点から望ましい。

これらの課題に対して、本研究では各ドメインで訓練したアダプタ [3]（事前学習モデルに残差接続した軽量な学習可能ネットワーク）を逐次的に平均化し [4]、1つのアダプタにマージして推論する方法を提案する。軽量なネットワークであるアダプタのみを訓練することで、事前学習モデルの汎化能力を維持しつつ、ドメイン固有の特徴を効率的に学習できる。従来手法では、ドメイン固有のアダプタをすべて保持する方法 [5] の性能が高いが、ドメインの増加に伴い推論時間が増加してしまう問題がある。これに対し、提案手法では、ドメイン固有のアダプタを1つにマージすることで、推論時間を一定に保つことができる。

## 2 提案手法

提案手法は、継続学習の中で、プロトタイプに基づくクラス分類法に区分される [1]。プロトタイプは各クラスの訓練データに対する平均特徴量として定義され、推論時には入力データは類似度が最も高いプロトタイプのクラスに分類される。

アダプタマージの文脈では、過去のプロトタイプの位置を現在のアダプタに対してどのように再配置するかが破滅的忘却を防ぐための鍵となる。もし過去のドメインの訓練データが利用できるならば、アダプタの再訓練による再配置が可能であるがアクセスできないため不可能である。この制約に対して、提案手法は各ドメインのプロトタイ

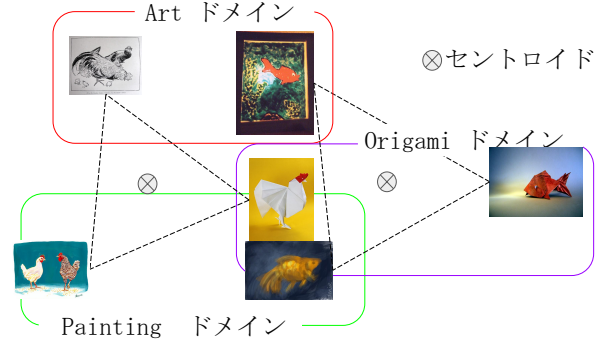


図1 アダプタマージにおけるプロトタイプの再配置

プの重心に基づいてプロトタイプを再配置する方法を導入する（図1）。具体的な手順は以下の通りである。

### 1. ドメイン固有アダプタの学習：

各ドメインが提示されるたびに、そのドメイン専用のアダプタを学習する。この過程では、事前学習モデルの重みを固定（フリーズ）し、アダプタのパラメータのみを更新する。アダプタマージが成功するように、同じ初期値を使って各アダプタを訓練している [4]。

### 2. アダプタの逐次マージ：

各ドメイン  $d$  のアダプタ  $\mathcal{A}_d$  を逐次的にマージすることで、全ドメインの情報を扱う統合アダプタ  $\bar{\mathcal{A}}_d$  を構築する。アダプタのマージでは、アダプタのパラメータを逐次的に平均する。

$$\bar{\theta}_d = \bar{\theta}_{d-1} + \frac{\theta_d - \bar{\theta}_{d-1}}{d} \quad (1)$$

ここで、 $\theta_d, \bar{\theta}_d$  はそれぞれアダプタ  $\mathcal{A}_d, \bar{\mathcal{A}}_d$  のパラメータである。

次に、得られた統合アダプタを利用して、ドメイン  $d$  のクラス  $c$  のプロトタイプ  $\mathbf{p}_{d,c}$  を入力データ  $\mathbf{x} \in \mathcal{V}_d$ （ドメイン  $d$  の検証データセット）の特徴量平均として求める。

$$\mathbf{p}_{d,c} = \frac{\sum_{(\mathbf{x}, y) \in \mathcal{V}_t} \phi(\mathbf{x}) \cdot \mathbb{I}(y = c)}{\sum_{(\mathbf{x}, y) \in \mathcal{V}_t} \mathbb{I}(y = c)} \quad (2)$$

ここで、 $\phi(\mathbf{x})$  は特徴ベクトル、 $\mathbb{I}(\cdot)$  は指示関数で

Adapter merge for scalable domain incremental learning

<sup>†</sup> Yamato Mihara, Chiba University

<sup>‡</sup> Takuma Fukuda, Chiba University

<sup>§</sup> Kazuhiko Kawamoto, Chiba University



図2 ImageNet-R 画像例

ある。全てのプロトタイプを連結した行列をドメイン  $d$  のプロトタイプ  $\mathbf{P}(\bar{\mathcal{A}}_d)$  として定義する。

### 3. プロトタイプの再配置：

推論時には、各ドメインのプロトタイプ  $\mathbf{P}(\bar{\mathcal{A}}_i), i = 1, \dots, d$  から全ドメインのデータに対応できる位置へプロトタイプを再配置する必要がある。図1のように、提案手法では再配置後のプロトタイプ  $\hat{\mathbf{P}}(\bar{\mathcal{A}}_d)$  を各プロトタイプの重心により定義する。

$$\hat{\mathbf{P}}(\bar{\mathcal{A}}_d) = \mathbb{E}_i[\mathbf{P}(\bar{\mathcal{A}}_i)] \quad (3)$$

この再配置により、単一の統合アダプタで全ドメインのデータを分類できるようになる。

## 3 評価実験

本研究では、ImageNet-R データセット (図2) を用いて、画像分類タスクで評価した。事前学習モデルには ImageNet-21K で訓練した Vision Transformer [6] を使用する。評価では、異なるシード値で5回検証し、標準的な評価指標である最終精度 (現在のドメインに対する分類精度)  $A_D$  と平均精度 (現在のドメインまでの平均分類精度)  $\bar{A}$  を用いる。ベースラインは、事前訓練モデルによってプロトタイプを構築する手法 (SimpleDIL) である。

表1より、提案手法の最終精度と平均精度は両者とも SimpleDIL よりも高く、提案手法の有効性を示している。さらに、ドメイン増分に伴う最終精度と平均精度の変化を図3,4に示すが、すべてのドメインにおいて提案手法が SimpleDIL を上回っていることが確認できる。

## 4 おわりに

本研究では、ドメイン増分学習に対して、推論時間を一定に保ちつつ、破滅的忘却を抑制するためにアダプタマージ法を提案した。提案手法では、ドメイン増分に対応するために、あるクラスのプロトタイプの位置を複数ドメインでの重心に再配置している。一方で、表1に示すように、精度向上は限定的で改善の余地は大きい。今後は、クラスのプロトタイプを一つの重心に集約するのではなく、各ドメインでのクラスプロトタイプを保持しつつ再配置する方法 [7] を検討したい。

表1 実験結果

手法	$A_D$	$\bar{A}$
SimpleDIL	18.75	40.72
<b>Ours</b>	<b>19.62</b>	<b>44.18</b>




図3 ImageNet-R における  $A_D$  の推移




図4 ImageNet-R における  $\bar{A}$  の推移

謝辞：本研究は JSPS 科研費 23K24914 の助成を受けたものです。

## 参考文献

- [1] D.W.Zhou et al., Continual Learning with Pre-Trained Models: A Survey, IJCAI, 8363-8371, 2024.
- [2] R.M.French, Catastrophic forgetting in connectionist networks. Trends in Cognitive Sciences, 3, 128-135, 1999.
- [3] E.J Hu et al., LoRA: Low-Rank Adaptation of Large Language Models, ICLR, 2022.
- [4] M.Wortsman et al., Model soups: averaging weights of multiple fine-tuned models improves accuracy without increasing inference time, ICML, 23965-23998, 2022.
- [5] D.W.Zhou et al., Expandable Subspace Ensemble for Pre-Trained Model-Based Class-Incremental Learning. CVPR, 23554-23564, 2024.
- [6] A.Dosovitskiy, An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale, ICLR, 2021.
- [7] T.Fukuda, H.Kera, K.Kawamoto, Adapter Merging with Centroid Prototype Mapping for Scalable Class-Incremental Learning, arXiv preprint, arXiv:2412.18219, 2024.